



## **TMDB Film Başarı Tahmini**

*Makine Öğrenmesi ile Film Kalitesi Sınıflandırması*

BIL4036-Yapay Zekanın Temelleri

2026

Hazırlayan

Mehmet Emirhan Oğuz

230601048

---

## İçindekiler

|                                                        |   |
|--------------------------------------------------------|---|
| 1. Giriş ve Amaç .....                                 | 3 |
| 2. Veri Seti .....                                     | 3 |
| 2.1 Kaynak ve Kapsam .....                             | 3 |
| 2.2 Eksik Veri Analizi.....                            | 3 |
| 3. Özellik Mühendisliği .....                          | 3 |
| 3.1 Temel Özellikler .....                             | 3 |
| 3.2 Oyuncu ve Yönetmen Geçmiş Skorları .....           | 3 |
| 4. Modelleme ve Deneyler.....                          | 4 |
| 4.1 Hedef Değişken ve Sınıf Dengesi .....              | 4 |
| 4.2 Üçlü Sınıflandırma Denemesi.....                   | 4 |
| 4.3 İkili Sınıflandırma — Keskin Sınır Yaklaşımı ..... | 4 |
| 4.4 Model Seçimi — HistGradientBoostingClassifier..... | 4 |
| 5. Sonuçlar ve Değerlendirme.....                      | 4 |
| 5.1 Model Performansı.....                             | 4 |
| 5.2 Özellik Önem Analizi .....                         | 5 |
| 5.3 Türe Göre Model Performansı .....                  | 5 |
| 6. Tartışma ve Sonuç.....                              | 5 |

---

## 1. Giriş ve Amaç

---

Bir filmin kaliteli olup olmayacağını önceden tahmin etmek hem izleyiciler hem de yapım şirketleri açısından büyük değer taşımaktadır. Bu çalışmada, The Movie Database (TMDB) platformundan API aracılığıyla elde edilen 1990–2026 yılları arasını kapsayan 27027 filmlik veri seti üzerinde, bir filmin "başarılı" sayılıp sayılmayacağını tahmin eden bir makine öğrenmesi modeli geliştirilmiştir. Çalışma kapsamında başarı kriteri, TMDB kullanıcı puanının 7,0'ın üzerinde olması şeklinde tanımlanmıştır.

Projenin temel amacı, filmin bütçesi, türü ve popüleritesi gibi geleneksel değişkenlerin ötesine geçerek yönetmen ve oyuncu geçmişinin tahmin gücünü ölçmektir. Bu yaklaşım, "deneyimli ve kaliteli bir kadronun filme katılması, filmin başarısını ne ölçüde öngörebilir?" sorusunu nicel bir çerçevede ele almaktadır.

## 2. Veri Seti

---

### 2.1 Kaynak ve Kapsam

Veri seti, TMDB'nin resmi API'si aracılığıyla doğrudan çekilmiştir. Bu yöntem, hazır CSV dosyalarına kıyasla daha güncel ve kontrol edilebilir bir veri akışı sağlamıştır. Nihai veri seti; 1990–2026 yılları arasında yayımlanmış, en az 50 oy almış ve "Released" (yayımlanmış) statüsündeki 27027 filmden oluşmaktadır. Her film kaydı; kimlik bilgileri, puan metrikleri, finansal veriler, türler ve teknik özellikler ile oyuncu ve ekip bilgileri olmak üzere üç ana kategoride toplam 39 özellik içermektedir.

### 2.2 Eksik Veri Analizi

Ham veri çekildiğinde bazı sütunlarda eksik kayıtlar tespit edilmiştir. Film başlığı ve çıkış tarihi sütunlarında 480 civarında eksik değer mevcuttu; bu filmler analiz dışı bırakıldı. Bütçe ve hasılat sütunlarındaki eksiklikler 0 ile dolduruldu, çünkü bu durum büyük ölçüde veri girişi yapılmamış ya da bütçesi açıklanmamış projelere karşılık gelmektedir. Film süresi (runtime) için ise veri setinin tamamının medyanı kullanılarak atama yapıldı; bu yöntem, aykırı değerlere karşı ortalamadan daha dayanıklıdır. Yönetmen ve oyuncu bilgisi bulunmayan kayıtlara "Unknown" etiketi atanarak bu bilginin yokluğu da model için anlamlı bir özellik hâline getirildi.

## 3. Özellik Mühendisliği

---

### 3.1 Temel Özellikler

Model eğitiminde kullanılan sayısal özellikler; film süresi, bütçe, hasılat, popülerite skoru ve yayımlanma yılıdır. Dil bilgisi, LabelEncoder ile sayısal formata dönüştürülmüştür. Film türleri ise veri setinde tespit edilen 19 farklı kategori için ikili (0/1) sütunlara ayrılmış ve one-hot encoding yöntemiyle temsil edilmiştir.

### 3.2 Oyuncu ve Yönetmen Geçmiş Skorları

Bu çalışmanın en özgün katkısı, her film için oyuncu ve yönetmen geçmişine dayalı dört yeni özelliğin üretilmesidir. Yönetmenin önceki filmlerinin ortalama TMDB puanı (director\_avg\_rating) ve yönetmenin toplam film sayısı (director\_experience) hesaplanmıştır. Bunlara ek olarak, filmdeki ilk beş oyuncunun geçmiş film ortalama puanı (cast\_avg\_rating) ve bu oyuncuların ortalama film deneyimi (cast\_experience) de özellik olarak eklenmiştir.

Bu yaklaşımın iki önemli işlevi bulunmaktadır. Birincisi, deneyim skoru olarak kullanılan film sayısı metriği, çok sayıda projede yer almış oyuncuları tanımlamayı mümkün kılmaktadır. İkincisi, ortalama puan metriği ise bu oyuncuların geçmiş projelerinin kalitesini yansıtarak yalnızca aile bağlantısı ya da tanınırlık nedeniyle büyük yapımlara dahil olan isimlerin düşük geçmiş puan ortalamasıyla ayırt edilmesine olanak tanımaktadır.

Söz konusu geçmiş skorlar yalnızca eğitim seti üzerinden hesaplanmış ve test setine uygulanmıştır; bu sayede veri sızıntısı (data leakage) riski ortadan kaldırılmıştır.

## 4. Modelleme ve Deneyler

### 4.1 Hedef Değişken ve Sınıf Dengesi

Sürekli bir değer olan TMDb puanı, 7,0 eşik değeri kullanılarak ikili sınıfa dönüştürülmüştür: 7,0 ve üzeri "başarılı" (1), altı ise "başarısız" (0) olarak etiketlenmiştir. Bu eşik belirlenmesinde, veri setindeki puan dağılımının ortalama ve standart sapması göz önünde bulundurulmuştur.

Ham veri setinde başarılı ve başarısız film sayıları arasında belirgin bir dengesizlik gözlemlenmiştir. Bu sorun, resample fonksiyonu ile azınlık sınıfı (başarılı filmler) örneklenerek eğitim setinde her iki sınıftan 16.814'er örnek elde edilmesiyle giderilmiştir.

### 4.2 Üçlü Sınıflandırma Denemesi

İkili sınıflandırmadan önce, filmler "kötü" ( $<6,0$ ), "ortalama" ( $6,0-7,0$ ) ve "iyi" ( $>7,0$ ) şeklinde üç kategoriye ayrılarak sınıflandırma denenmiştir. Ancak bu yaklaşım yalnızca %54 doğruluk oranı üretmiştir. Bunun temel nedeni, "ortalama" kategorisinin birbirine çok yakın puan değerleri (örneğin 5,9 ile 6,1) arasında yapay bir sınır oluşturması ve model için örtüşen bir karar bölgesi yaratmasıdır. Puan dağılımının 6-7 bandında yoğunlaşması da bu sınıfı baskın hâle getirmiş ve modelin büyük çoğunluğu "ortalama" olarak tahmin etme eğilimine girmesine neden olmuştur.

### 4.3 İkili Sınıflandırma — Keskin Sınır Yaklaşımı

Üçlü sınıflandırmanın yetersizliğini aşmak amacıyla "ortalama" olarak etiketlenen filmler ( $6,0-7,0$  arasındaki tüm kayıtlar) hem eğitim hem de test setinden tamamen çıkarılmış, hedef yalnızca net "kötü" ve "iyi" filmlerle yeniden tanımlanmıştır. Bu yöntem, modelin karar sınırlarını belirginleştirerek doğruluk oranını %82,4 seviyesine taşımıştır.

### 4.4 Model Seçimi — HistGradientBoostingClassifier

Başlangıç modeli olarak Random Forest kullanılmış ve %81 doğruluk elde edilmiştir. Daha gelişmiş bir alternatif olarak HistGradientBoostingClassifier tercih edilmiştir. Bu model, histogram tabanlı gradyan artırma yöntemiyle çalışır; büyük veri setlerinde Random Forest'a kıyasla hem daha hızlı hem de daha esnek bir öğrenme süreci sunar.

Hiperparametre optimizasyonu için RandomizedSearchCV kullanılmış; öğrenme hızı (learning\_rate), ağaç derinliği (max\_depth) ve iterasyon sayısı (max\_iter) gibi parametreler 5 katlı çapraz doğrulama ile 30 farklı kombinasyonda test edilmiştir. En iyi sonucu veren parametreler max\_depth: 4 ve learning\_rate: 0,1 olarak belirlenmiştir.

## 5. Sonuçlar ve Değerlendirme

### 5.1 Model Performansı

Hiperparametre optimizasyonu tamamlanmış HistGradientBoostingClassifier modeli, test setinde %83,3 doğruluk oranı elde etmiştir. Başarılı film sınıfında F1 skoru %77, başarısız film sınıfında ise %85 olarak ölçülmüştür. 5 katlı çapraz doğrulama ile elde edilen sonuçlar, bu performansın eğitim verisine özgü bir ezberleme durumu olmadığını, modelin farklı veri bölümleri üzerinde de tutarlı biçimde genellendiğini göstermektedir.

| Test doğruluğu: 0.833 |           |        |          |         |
|-----------------------|-----------|--------|----------|---------|
|                       | precision | recall | f1-score | support |
| Kötü film             | 0.86      | 0.88   | 0.87     | 1817    |
| İyi film              | 0.79      | 0.75   | 0.77     | 1084    |
| accuracy              |           |        | 0.83     | 2901    |
| macro avg             | 0.82      | 0.82   | 0.82     | 2901    |
| weighted avg          | 0.83      | 0.83   | 0.83     | 2901    |

## 5.2 Özellik Önem Analizi

Modelin karar sürecinde en belirleyici faktörün `cast_avg_rating` (%31) olduğu görülmüştür. Yönetmenin geçmiş film ortalama puanı (`director_avg_rating`) ikinci sırada yer almakta olup bu iki özellik birlikte modelin toplam karar ağırlığının yaklaşık %56'sını oluşturmaktadır. Popülerlik, süre ve yıl orta önem düzeyinde kalırken, tüm 19 film türünün toplamının önem ağırlığı yalnızca %8,3 olarak tespit edilmiştir.

Bu bulgu, bir filmin türünün tek başına kalitesini belirlemediğini, asıl belirleyicinin o filmin arkasındaki isimler olduğunu ortaya koymaktadır. Türsel farklılıklardan bağımsız olarak, deneyimli ve geçmişte kaliteli işler üretmiş bir kadronun varlığı, modelin başarılı tahmin yapmasında en güçlü sinyal olmaya devam etmektedir.

## 5.3 Türe Göre Model Performansı

Aynı model, her film türü için ayrı ayrı değerlendirildiğinde, türler arasında anlamlı performans farklılıkları gözlemlenmiştir. Horror filmlerinde %97 doğruluğa ulaşılmıştır; bu türde başarılı film oranının yalnızca %10 olması, modelin büyük çoğunluğu doğru biçimde "başarısız" olarak sınıflandırmasını kolaylaştırmaktadır. Öte yandan Tarih ve Savaş türlerinde başarı oranı yarıya yakın olduğundan model bu filmleri ayırt etmekte en çok zorlandığı görülmüştür. Drama türü de geniş kapsam alanı ve yüksek başarılı film oranı nedeniyle %85 ile görece düşük performans sergilemiştir.

## 6. Tartışma ve Sonuç

Bu çalışma, film kalitesi tahmininde oyuncu ve yönetmen geçmişinin bütçe ve tür gibi geleneksel değişkenlere kıyasla çok daha belirleyici bir rol oynadığını nicel olarak ortaya koymuştur. Modelin %83 doğruluk oranıyla elde ettiği sonuç, yalnızca nesnel ve önceden erişilebilir verilerle bu tahminin yapılabildiğini göstermektedir. Çalışmanın temel kısıtı, oyuncu ve yönetmen verilerinin yalnızca 4803 filmlik bir veri setinden türetilmiş olmasıdır; bu durum, 27027 filmin bir kısmı için bu özelliklerin hesaplanamamasına yol açmıştır. Proje, makine öğrenmesinin kültürel ürünlerin değerlendirilmesine nasıl uygulanabileceğini somut bir örnekle göstermekte ve özellik mühendisliğinin tahmin performansına katkısını ortaya koymaktadır.

## Kaynaklar

- [1] The Movie Database (TMDB) API. <https://www.themoviedb.org/documentation/api>
- [2] Pedregosa, F. ve ark. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [3] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [4] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.